Desenvolvimento e avaliação uma ferramenta baseada em Inteligência Artificial capaz de converter solicitações em linguagem natural para consultas SQL, visando apoiar as atividades de suporte e desenvolvimento em um ambiente corporativo real.

Luiz Mário Marangon[1], **Roger Sá da Silva**[1]

[1]Instituto Federal de Educação, Ciência e Tecnologia do Rio Grande do Sul (IFRS)
Campus Veranópolis – BR-470, Km 172, 6500, Bairro Sapopema
CEP 95330-000 – Veranópolis – RS – Brasil

luizmarangonzz11@gmail.com, roger.silva@veranopolis.ifrs.edu.br

Abstract. *The growing volume of data stored in relational databases has increased the demand for SQL queries to retrieve information, generate reports, and support decision-making processes. However, creating such queries requires specialized technical knowledge, which may limit data accessibility and place an additional burden on support and development teams. In this context, this work proposes the development of an Artificial Intelligence-based tool capable of converting natural language requests into executable SQL queries. The proposed solution employs the SQLCoder model, locally executed through the Ollama platform and integrated into an application developed with Java and Spring Boot, connected to a PostgreSQL database. Through a case study conducted in a corporate environment, this research aims to evaluate the accuracy and feasibility of the Text-to-SQL approach as a mechanism for supporting information retrieval. The expected outcomes include reducing the time required to create queries, increasing the productivity of technical teams, and democratizing access to corporate data.*
keywords: *Artificial Intelligence; Large Language Models; Text-to-SQL; SQL; Relational Database.*

Resumo. *O crescente volume de dados armazenados em bancos de dados relacionais tem aumentado a demanda por consultas SQL para obtenção de informações, geração de relatórios e suporte à tomada de decisão. Entretanto, a elaboração dessas consultas exige conhecimento técnico especializado, o que pode limitar o acesso aos dados e sobrecarregar equipes de suporte e desenvolvimento. Nesse contexto, este trabalho propõe o desenvolvimento de uma ferramenta baseada em Inteligência Artificial capaz de converter solicitações em linguagem natural em consultas SQL executáveis. A solução utiliza o modelo SQLCoder, executado localmente por meio da plataforma Ollama, integrado a uma aplicação desenvolvida em Java e Spring Boot e conectada a um banco de dados PostgreSQL. Por meio de um estudo de caso em ambiente corporativo, busca-se avaliar a precisão e a viabilidade da abordagem Text-to-SQL como mecanismo de apoio à recuperação de informações. Espera-se que a solução contribua para a redução do tempo gasto na elaboração de consultas, aumento*

da produtividade das equipes técnicas e democratização do acesso aos dados corporativos.
Palavras-chave: *Inteligência Artificial. Processamento de Linguagem Natural. Large Language Models. Text-to-SQL. SQLCoder. Banco de Dados.*

1. Introdução

Com o aumento gradual da digitalização de processos organizacionais e modernização de empresas para se adequar a nota tecnologias, houve um crescimento exponencial na quantidade de dados gerados e armazenados em bancos de dados relacionais. Nesse contexto, o banco de dados se tornou cada vez mais relevante para as organizações como um todo, criando uma preocupação para o armazenamento, gerenciamento e recuperação dessas informações essenciais para os processos operacionais e estratégicos.

Paralelamente, com o aumento do volume de dados, cresce também a necessidade de consultas frequentes que auxiliam a tomada de decisão através de relatórios, análise estatística, indicadores além da manutenção da preocupação em manutenção destas informações. Esse dependência técnica faz com que tarefas simples como confecção de relatórios ou manutenção de dados em larga escala, demandem a atuação de profissionais especializados, que por vezes, demandam muito tempo para atender estes requisitos.

Em empresas de desenvolvimento de software, essa situação é ainda mais evidente. Equipes de suporte e programação frequentemente precisam realizar consultas diretamente no banco de dados para atender solicitações de clientes, investigar inconsistências, gerar relatórios personalizados e efetuar ajustes em informações armazenadas pelos sistemas. Muitas dessas tarefas são repetitivas e consomem tempo significativo dos profissionais envolvidos, impactando diretamente a produtividade da equipe e o tempo de resposta aos usuários.

Simultaneamente, os recentes avanços na área da Inteligência Artificial, impulsionados pela modernização do campo do Processamento de Linguagem Natural (PLN), têm possibilitado novas maneiras de intervenção para facilitar a interação entre usuários e sistemas computacionais. O desenvolvimento dos Modelos de Linguagem de Grande Escala (Large Language Models – LLMs) ampliou significativamente a capacidade das máquinas de compreender e gerar linguagem natural, tornando viável a construção de sistemas capazes de interpretar perguntas formuladas em linguagem humana e convertê-las em instruções executáveis, como por exemplo consultas em SQL.

Nesse cenários, destaca-se a área de pesquisa conhecida como Text-to-SQL, que visa transformas consultas escritas em linguagem natural em comandos SQL executáveis dentro de banco de dados relacionais. Essa metodologia tem potencial para reduzir a dependência de conhecimentos técnicos específicos, tornando o acesso às informações mais rápido e intuitivo até mesmo para usuários que não tenham muito contato com essa tecnologia.

Dentre os modelos disponíveis que atendem estes requisitos, o SQLCoder se destacou por ter sido desenvolvido especificamente para tarefas de geração de consultas SQL a partir de descrição em linguagem natual. Sua execução local por meio da plataforma Ollama oferece vantagens relacionadas à privacidade dos dados, redução de custos operacionais e maior controle sobre o ambiente de execução, características importantes para aplicações em ambientes corporativos.

Diante desse cenário, este trabalho propõe o desenvolvimento de uma ferramenta capaz de converter solicitações formuladas em linguagem natural para consultas SQL, utilizando o modelo SQLCoder executado através do Ollama e integrado a um banco de dados PostgreSQL com uma interface amigável e intuitiva. A proposta será aplicada em um contexto organizacional real, buscando apoiar as atividades das equipes de suporte e desenvolvimento, reduzindo o tempo gasto na elaboração manual de consultas e na obtenção de informações armazenadas em banco de dados.

Nesse sentido, a pesquisa apresenta relevância acadêmica e prática ao explorar a aplicação de modelos de linguagem em tarefas de Text-to-SQL, contribuindo para a ampliação do conhecimento sobre o tema e para o desenvolvimento de ferramentas capazes de otimizar processos de consulta, análise e recuperação de informações em ambientes corporativos.

Por fim, este trabalho está organizado da seguinte maneira: A seção 1 apresenta a introdução ao tema, contextualizando o problema e os objetivos da pesquisa; A seção 2 descreve os procedimentos metodológicos adotados. A seção 3 aborda a fundamentação teórica necessária para compreensão dos conceitos envolvidos. A seção 4 apresenta o produto desenvolvido. A seção 5 discute os resultados obtidos durante a avaliação da solução. Por último, a seção 6 apresenta as considerações finais, destacando as contribuições, limitações e possibilidades de trabalhos futuros.

2. Metodologia

Esta pesquisa pode ser caracterizada como de natureza aplicada, uma vez que tem como objetivo o desenvolvimento de uma solução prática voltada à melhoria e otimização do acesso à informação em bancos de dados por meio de linguagem natural. Nesse contexto, busca-se propor e implementar um sistema baseado em Modelos de Linguagem de Grande Escala (LLMs) capaz de transformar consultas em linguagem natural em comandos SQL executáveis.

Do ponto de vista metodológico, a pesquisa apresenta caráter tecnológico, combinando abordagens qualitativas e quantitativas. A dimensão qualitativa está relacionada à análise de trabalhos correlatos e das tecnologias empregadas, como LLMs, arquiteturas de modelos de linguagem e ferramentas de execução local. Já a abordagem quantitativa é utilizada na avaliação do desempenho do sistema desenvolvido, por meio da mensuração da precisão das consultas SQL geradas pelo modelo.

Quanto aos objetivos, a pesquisa pode ser classificada como exploratória e descritiva. É exploratória por investigar o uso de LLMs aplicados à geração de consultas em linguagem natural. Ao mesmo tempo, é descritiva por buscar analisar e caracterizar o comportamento do sistema desenvolvido, especialmente no que se refere à qualidade e precisão das respostas geradas.

2.1. Estudo de Caso

O presente trabalho será desenvolvido com base em um estudo de caso realizado na empresa onde o autor atua profissionalmente.

A empresa desenvolve um sistema completo ERP que armazena informações em banco de dados relacional PostgreSQL. Durante as atividades de suporte e desenvolvimento, é frequente a necessidade de execução de consultas SQL para geração de relatórios

específicos, análise de inconsistências de dados e realização de ajustes solicitados pelos usuários.

Essas operações exigem conhecimento técnico especializado e demandam tempo considerável dos profissionais envolvidos, sobrecarregando a equipe e atrasando demais demandas.

Diante desse cenário, será desenvolvido um protótipo baseado em Inteligência Artificial capaz de converter solicitações em linguagem natural para consultas SQL, buscando reduzir o tempo necessário para obtenção das informações e aumentar a produtividade da equipe.

2.2. Levantamento Bibliográfico

Inicialmente foi realizado um levantamento bibliográfico com o objetivo de identificar estudos relacionados à conversão de linguagem natural para SQL, Processamento de Linguagem Natural, Machine Learning, Deep Learning e Modelos de Linguagem de Grande Escala.

As buscas foram realizadas por meio da plataforma Google Acadêmico, utilizando operadores booleanos para combinar termos relacionados ao tema da pesquisa. Entre os termos empregados destacam-se: ”LLM”, ”Text-to-SQL”, ”Machine Learning”, ”Natural Language Processing”, ”Database”e ”SQL”. Na pesquisa, houve a tendência de escolha em trabalhos realizados no período de 2020 a 2026, para abrangência de fontes e pesquisas atualizadas na área.

Após a identificação dos trabalhos, foi realizado um processo de seleção baseado na relevância, aderência ao tema e atualidade das publicações. Os estudos selecionados serviram como base para a fundamentação teórica e para a definição da arquitetura proposta.

2.3. Desenvolvimento da Solução

A solução proposta consiste no desenvolvimento de uma interface capaz de converter perguntas formuladas em linguagem natural para consultas SQL executáveis em um banco de dados relacional.

O sistema será composto por uma interface de usuário, uma API responsável pela comunicação com o modelo de linguagem e um banco de dados PostgreSQL para armazenamento das informações.

Para a geração automática das consultas SQL será utilizado o modelo SQLCoder, executado localmente por meio da plataforma Ollama. A escolha dessa tecnologia deve-se à sua especialização em tarefas Text-to-SQL, permitindo maior precisão na geração das consultas quando comparado a modelos generalistas, além de ser uma ferramenta open-source, permitindo o desenvolvimento aberto e sem custos.

2.4. Base de Dados

Para a validação da solução proposta, serão utilizadas cinco bases de dados provenientes do ambiente corporativo da empresa em que o estudo será realizado. Essas bases foram selecionadas por representarem diferentes cenários de utilização do sistema e por

contemplarem informações frequentemente acessadas pelas equipes de suporte e desenvolvimento.

As bases escolhidas abrangem diferentes módulos do sistema corporativo, incluindo dados cadastrais, informações financeiras, registros de operações, movimentações de usuários e dados relacionados à emissão de documentos fiscais. A utilização de múltiplas bases tem como objetivo avaliar a capacidade do modelo de linguagem em compreender diferentes esquemas de banco de dados e gerar consultas SQL adequadas para cada contexto.

Por questões de confidencialidade e proteção das informações corporativas, os nomes das bases e os dados utilizados não serão divulgados. Durante os testes, serão utilizados ambientes controlados e dados anonimizados sempre que necessário, garantindo conformidade com as políticas internas da organização e com a Lei Geral de Proteção de Dados (LGPD).

Além dos dados propriamente ditos, os esquemas das bases de dados serão utilizados como contexto para o modelo SQLCoder. Informações como nomes de tabelas, colunas e relacionamentos serão fornecidas ao modelo durante o processo de geração das consultas SQL, permitindo maior precisão na interpretação das solicitações realizadas em linguagem natural.

A utilização dessas bases permite avaliar o desempenho da ferramenta em situações reais de trabalho, aproximando os resultados obtidos das demandas enfrentadas diariamente pelas equipes técnicas da empresa.

2.5. Avaliação do Sistema

A avaliação do sistema será realizada por meio de testes utilizando consultas formuladas em linguagem natural. As perguntas serão classificadas em três níveis de complexidade: simples, intermediárias e complexas.

As consultas geradas pelo modelo serão comparadas com consultas SQL previamente definidas como corretas para cada cenário de teste. Os critérios de avaliação considerados serão:

- Precisão da consulta gerada;
- Correção sintática da SQL produzida;
- Correção semântica da SQL produizada;
- Capacidade de interpretar perguntas em potuguês;
- Capacidade de fazer consultas complexas em múltiplas tabelas;

Os resultados obtidos serão utilizados para avaliar a viabilidade do uso de modelos de linguagem especializados na geração automática de consultas SQL.

3. Fundamentação Teórica

3.1. Bancos de Dados Relacionais

Os bancos de dados constituem um dos principais mecanismos utilizados para armazenamento, organização e recuperação de informações em sistemas computacionais. Segundo Elmasri e Navathe (2018), um banco de dados pode ser definido como uma coleção organizada de dados relacionados, projetada para atender às necessidades de uma organização ou aplicação específica.

Entre os diversos modelos existentes, o modelo relacional destaca-se por sua ampla adoção em ambientes corporativos. Proposto por Codd (1970), esse modelo organiza os dados em tabelas compostas por linhas e colunas, permitindo o estabelecimento de relacionamentos entre diferentes conjuntos de informações.

A principal vantagem dos bancos de dados relacionais está na capacidade de garantir integridade, consistência e independência dos dados. Além disso, o modelo relacional oferece mecanismos eficientes para consulta e manipulação das informações, tornando-se o padrão predominante em sistemas de informação modernos.

3.2. Linguagem SQL

A Structured Query Language (SQL) é a principal linguagem utilizada para criação, manipulação e consulta de dados em bancos de dados relacionais. Consolidou-se como o padrão para interação com Sistemas Gerenciadores de Bancos de Dados (SGBDs), sendo amplamente suportada por plataformas como SQL Server, PostgreSQL, MySQL e Oracle. Sua ampla adoção deve-se à capacidade de fornecer uma forma padronizada e declarativa de acesso aos dados, permitindo que usuários e aplicações especifiquem quais informações desejam recuperar ou modificar sem a necessidade de definir detalhadamente os procedimentos de execução (ELMASRI et al, 2020).

Os comandos SQL são tradicionalmente agrupados em categorias de acordo com sua finalidade. A Data Definition Language (DDL) é utilizada para criação e alteração de estruturas do banco de dados, incluindo tabelas, índices e restrições. A Data Manipulation Language (DML) permite inserir, atualizar, excluir e consultar registros armazenados. Já a Data Control Language (DCL) é responsável pelo gerenciamento de permissões de acesso, enquanto a Transaction Control Language (TCL) fornece mecanismos para controle de transações e garantia da consistência dos dados (ELMASRI; NAVATHE, 2010).

Apesar de sua ampla adoção, a utilização da SQL exige conhecimento prévio da estrutura do banco de dados e de sua sintaxe específica. Usuários sem formação técnica frequentemente encontram dificuldades para construir consultas corretas e eficientes, especialmente em cenários que envolvem múltiplas tabelas e relacionamentos complexos. Essa limitação motivou o surgimento de pesquisas voltadas ao desenvolvimento de interfaces capazes de traduzir consultas em linguagem natural para comandos SQL, permitindo que usuários interajam com bancos de dados de maneira mais intuitiva e acessível.

3.3. Processamento de Linguagem Natural (PLN)

O Processamento de Linguagem Natural (PLN), conhecido internacionalmente como Natural Language Processing (NLP), é uma área interdisciplinar que combina conceitos de Ciência da Computação, Linguística e Inteligência Artificial com o objetivo de permitir que sistemas computacionais compreendam, interpretem e gerem linguagem humana de forma significativa. Segundo Jurafsky e Martin (2024), o principal objetivo do PLN é desenvolver métodos capazes de processar informações expressas em linguagem natural, aproximando a comunicação entre seres humanos e sistemas computacionais.

A arquitetura Transformer, proposta por Vaswani et al. (2017), representa um marco no PLN moderno. Diferentemente de arquiteturas recorrentes, o Transformer dispensa o uso de processamento sequencial e é inteiramente baseado em mecanismos de

attention. Sua estrutura é composta por blocos de encoder e decoder. O encoder é responsável por processar a sequência de entrada e gerar representações vetoriais contextualizadas, capturando relações entre todos os elementos da sequência por meio do mecanismo de self-attention. Já o decoder utiliza essas representações para gerar a saída, produzindo a sequência token a token, também com o auxílio de mecanismos de atenção que consideram tanto a entrada quanto os tokens já gerados.

Esse mecanismo permite que o modelo aprenda relações de longo alcance entre palavras, independentemente de sua posição na sequência, superando limitações de arquiteturas anteriores baseadas em redes recorrentes. Como resultado, o Transformer se tornou a base para os principais modelos de linguagem atuais, possibilitando avanços significativos na compreensão e geração de linguagem natural.

3.4. Conceitos gerais de Machine Learning e Deep Learning

O Machine Learning (aprendizado de máquina) é uma subárea da Inteligência Artificial que tem como objetivo desenvolver algoritmos capazes de aprender padrões a partir de dados, sem a necessidade de programação explícita para cada tarefa. Nessa abordagem, os sistemas são treinados com exemplos, identificando relações estatísticas que permitem realizar previsões ou classificações sobre novos dados. Segundo Bezerra (2016), o aprendizado de máquina representa uma mudança de paradigma em relação aos sistemas baseados em regras, uma vez que o conhecimento passa a ser inferido diretamente a partir dos dados.

Dentro desse contexto, o Deep Learning (aprendizado profundo) constitui uma subárea do Machine Learning baseada no uso de redes neurais artificiais com múltiplas camadas ocultas. Essas arquiteturas permitem o aprendizado hierárquico de representações, em que níveis mais baixos capturam padrões simples e níveis mais profundos combinam essas informações para representar conceitos mais complexos. De acordo com Bezerra (2016), o Deep Learning se destaca pela sua capacidade de modelar automaticamente representações relevantes dos dados, reduzindo a necessidade de engenharia manual de atributos (feature engineering).

O avanço do Deep Learning tem sido fundamental para o desenvolvimento de modelos modernos de inteligência artificial, especialmente em tarefas que envolvem dados não estruturados, como texto, imagens e áudio. No contexto de Processamento de Linguagem Natural, essas técnicas permitem o treinamento de modelos mais robustos e eficientes, sendo a base para arquiteturas avançadas como os modelos de linguagem em larga escala (Large Language Models).

3.5. Large Language Models (LLMs)

Os Large Language Models (LLMs) constituem uma classe de modelos de linguagem baseados em redes neurais profundas, treinados com grandes volumes de dados textuais e projetados para compreender e gerar linguagem natural de forma contextualizada. Esses modelos têm sido amplamente estudados e aplicados em diferentes tarefas de processamento de linguagem natural, como geração de texto, resposta a perguntas, sumarização e sistemas conversacionais (ZHAO et al., 2023).

A construção dos LLMs está diretamente associada ao avanço das arquiteturas baseadas em Transformers. Essa arquitetura substitui mecanismos recorrentes por estruturas

baseadas exclusivamente em attention, permitindo maior paralelização do treinamento e melhor modelagem de dependências de longo alcance em sequências textuais.

Com base nessa arquitetura, os LLMs evoluíram para modelos de grande escala caracterizados pelo aumento significativo no número de parâmetros e no volume de dados utilizados no treinamento. Segundo Minaee et al. (2024), essa ampliação de escala resulta em melhorias expressivas na capacidade de generalização, além de possibilitar o surgimento de comportamentos emergentes, nos quais habilidades complexas aparecem naturalmente à medida que o modelo cresce, sem necessidade de programação explícita.

O uso de LLMs em ambientes práticos tem sido impulsionado pela sua capacidade de adaptação a diferentes tarefas a partir de instruções em linguagem natural, o que facilita sua integração em sistemas interativos. Essa flexibilidade torna os LLMs especialmente relevantes para aplicações que envolvem a interpretação de intenções do usuário e a geração de saídas estruturadas a partir de texto livre.

3.6. Text-to-SQL

Text-to-SQL, também conhecido como Natural Language to SQL (NL2SQL), é uma área de pesquisa que busca converter consultas formuladas em linguagem natural em comandos SQL executáveis. O principal objetivo dessa abordagem é permitir que usuários consultem bancos de dados relacionais sem a necessidade de conhecimento prévio da linguagem SQL.

Segundo Hong et al. (2025), o interesse por sistemas Text-to-SQL cresceu significativamente com a evolução dos Modelos de Linguagem de Grande Escala (LLMs) e a crescente demanda por soluções que facilitem o acesso a informações armazenadas em bancos de dados. Esses sistemas funcionam interpretando a intenção do usuário e relacionando-a com a estrutura do banco de dados para gerar consultas SQL semanticamente corretas.

Os sistemas Text-to-SQL podem ser classificados em três gerações principais: sistemas baseados em regras, que utilizam padrões previamente definidos; sistemas baseados em técnicas de Machine Learning, que aprendem a partir de exemplos; e sistemas baseados em LLMs, que utilizam modelos de linguagem avançados para compreender perguntas e gerar consultas de forma mais flexível e precisa.

4. Produto

4.1. Visão Geral da Solução

O produto desenvolvido consiste em uma ferramenta web capaz de converter solicitações formuladas em linguagem natural em consultas SQL executáveis em bancos de dados relacionais. A solução tem como objetivo auxiliar as equipes de suporte e desenvolvimento na obtenção de informações armazenadas em bancos de dados, reduzindo o tempo necessário para a elaboração manual de consultas e facilitando o acesso aos dados corporativos.

A proposta surgiu a partir da observação de demandas recorrentes no ambiente corporativo em que o estudo será aplicado. Frequentemente, profissionais das áreas de suporte e desenvolvimento precisam realizar consultas diretamente em bancos de dados para gerar relatórios, analisar inconsistências, validar informações ou atender solicitações

específicas de clientes. Essas atividades exigem conhecimento técnico em SQL e, muitas vezes, consomem uma parcela significativa do tempo da equipe.

Nesse contexto, a ferramenta busca simplificar esse processo por meio da utilização de um Modelo de Linguagem de Grande Escala (LLM) especializado em geração de consultas SQL. Dessa forma, os usuários poderão descrever suas necessidades em linguagem natural, utilizando frases em português, enquanto o sistema será responsável por interpretar a solicitação e gerar automaticamente a consulta SQL correspondente.

Além de contribuir para a redução do tempo gasto na elaboração de consultas, a solução busca padronizar o processo de obtenção de informações e reduzir erros decorrentes da construção manual de comandos SQL.

4.2. Arquitetura da Solução

A arquitetura da solução foi projetada seguindo o modelo cliente-servidor e é composta pelos seguintes componentes principais:

- Interface Web;
- API de integração;
- Modelo SQLCoder executado por meio da plataforma Ollama;
- Banco de dados PostgreSQL.

O fluxo de funcionamento do sistema seguirá as seguintes etapas:

1. O usuário insere uma solicitação em linguagem natural por meio da interface web;
2. A solicitação é encaminhada para a API da aplicação;
3. A API envia a requisição ao modelo SQLCoder, juntamente com informações sobre o esquema do banco de dados;
4. O modelo interpreta a solicitação e gera a consulta SQL correspondente;
5. A consulta gerada é apresentada ao usuário para validação;
6. Após a validação, a consulta pode ser executada no banco de dados PostgreSQL;
7. Os resultados obtidos são retornados à interface da aplicação;
8. Um profissional responsável realiza a conferência dos resultados obtidos, verificando se a consulta gerada está correta do ponto de vista sintático e semântico, bem como se atende à necessidade solicitada;
9. Após a validação final, as informações podem ser utilizadas para atender a demanda do cliente ou do setor solicitante.

A inclusão de uma etapa de validação humana busca aumentar a confiabilidade da solução, uma vez que modelos de linguagem podem produzir consultas sintaticamente válidas, mas semanticamente incorretas em determinados cenários.

4.3. Tecnologias Utilizadas

Para o desenvolvimento da solução serão utilizadas tecnologias amplamente difundidas no mercado e, preferencialmente, de código aberto, visando facilitar a implementação, manutenção e evolução futura do sistema.

O banco de dados PostgreSQL será utilizado para armazenamento das informações e execução das consultas geradas. A geração automática de SQL será realizada por meio do modelo SQLCoder, executado localmente utilizando a plataforma

Tecnologia	Finalidade
Java	Desenvolvimento do backend
Sring Boot	Implantação da API REST
PostgreSQL	Banco de dados relacional
Ollama	Execução local do modelo
SQLCoder	Geração automática do SQL, a partir da questão feita
HTML, CSS e Bootstrap7	Interface de usuário

Figura 1. Desenvolvido pelo autor

Ollama, permitindo maior controle sobre os dados processados e reduzindo a dependência de serviços externos.

A aplicação será desenvolvida utilizando tecnologias voltadas ao desenvolvimento web e integração de sistemas, responsáveis pela implementação da interface de usuário, comunicação com o modelo de linguagem e gerenciamento das requisições realizadas ao banco de dados.

4.4. Funcionalidade do Sistema

Inicialmente, o sistema disponibilizará as seguintes funcionalidades:

1. Consulta em Linguagem Natural
   O usuário faz perguntas em linguagem natural (em potuguês, por exemplo), sem necessariamente ter o contato com o SQL.

   Por exemplo:
   ”Quais clientes realizaram mais de cinco compras neste mês?”

2. Geração Automática do SQL
   Após o recebimento da solicitação, o modelo irá fazer a geração do SQL correspondente.

   Exemplo de reposta para a questão acima:

```sql
SELECT c.nome
FROM cliente c
JOIN pedidos p
    ON p.cliente_id = c.id
WHERE DATE_TRUNC('month', p.data) =
      DATE_TRUNC('month', CURRENT_DATE)
GROUP BY c.nome
HAVING COUNT(*) > 5;
```

3. Conferência da Consulta Gerada
   Antes da aplicação do SQL em produção, a consulta é consulta por um profissional que, além de conhecimentos em SQL, conhece como funciona as regras de negócio, sendo assim, identificando possíveis inconsistências ou erros de semântica ou sintática .

5. Resultados

Relate e analise os resultados obtidos, destacando evidências, testes, avaliações ou percepções decorrentes da aplicação do produto.

6. Considerações finais

Retome os objetivos do trabalho, sintetize as principais contribuições, apresente limitações e indique possibilidades de trabalhos futuros.

7. Referências

BEZERRA, Eduardo. Introdução à aprendizagem profunda. In: SIMPÓSIO BRASILEIRO DE BANCO DE DADOS (SBBD), 31., 2016, Salvador. *Anais [...]* Porto Alegre: Sociedade Brasileira de Computação, 2016.

BROWN, Tom B. et al. *Language Models are Few-Shot Learners*. 2020. Disponível em: https://arxiv.org/abs/2005.14165. Acesso em: 31 maio 2026.

CHOWDHARY, K. R. Natural Language Processing. In: CHOWDHARY, K. R. *Fundamentals of Artificial Intelligence*. New Delhi: Springer, 2020. p. 603–649. Disponível em: https://doi.org/10.1007/978-81-322-3972-7_19. Acesso em: 31 maio 2026.

DATE, C. J. *Introdução a sistemas de bancos de dados*. 8. ed. Rio de Janeiro: Elsevier, 2004.

DOUGLAS, Michael R. et al. *Large Language Models*. arXiv preprint, 2023. Disponível em: https://arxiv.org/abs/2307.05782. Acesso em: 31 maio 2026.

ELMASRI, Ramez; NAVATHE, Shamkant B. *Sistemas de banco de dados*. 7. ed. São Paulo: Pearson, 2018. Disponível em: https://plataforma.bvirtual.com.br. Acesso em: 31 maio 2026.

GIRAY, Louie. Prompt Engineering with ChatGPT: A Guide for Academic Writers. *Annals of Biomedical Engineering*, New York, v. 51, n. 12, p. 2629–2633, 2023. Disponível em: https://doi.org/10.1007/s10439-023-03272-4. Acesso em: 31 maio 2026.

JIANG, Y.; WANG, Y.; CHEN, C.; YANG, D.; ZHANG, C.; YU, Z.; YANG, H. *Prompt Engineering for Large Language Models: A Survey*. 2023. arXiv:2303.18223. Disponível em: https://arxiv.org/abs/2303.18223. Acesso em: 31 maio 2026.

MELTON, Jim. *SQL and Relational Theory: How to Write Accurate SQL Code*. 3. ed. Sebastopol: O'Reilly Media, 2022. Disponível em: https://books.google.com.br/books?id=0NnPEAAAQBAJ. Acesso em: 31 maio 2026.

VASWANI, Ashish et al. *Attention Is All You Need*. 2017. Disponível em: https://arxiv.org/abs/1706.03762. Acesso em: 31 maio 2026.

YANG, Jingfeng; JIN, Hongye; TANG, Ruixiang; HAN, Xiaotian; FENG, Qizhang; JIANG, Haoming; ZHONG, Shaochen; YIN, Bing; HU, Xia. Harnessing the

Power of LLMs in Practice: A Survey on ChatGPT and Beyond. *ACM Transactions on Knowledge Discovery from Data*, New York, v. 18, n. 6, art. 160, p. 1–32, jul. 2024. Disponível em: https://doi.org/10.1145/3649506. Acesso em: 31 maio 2026.

Boulic, R. and Renault, O. (1991). 3d hierarchies for animation. In Magnenat-Thalmann, N. and Thalmann, D., editors, *New Trends in Animation and Visualization*. John Wiley & Sons ltd.

Knuth, D. E. (1984). *The TEX Book*. Addison-Wesley, 15th edition.

Smith, A. and Jones, B. (1999). On the complexity of computing. In Smith-Jones, A. B., editor, *Advances in Computer Science*, pages 555–566. Publishing Press.